



2025年 SMBC Group GREEN × DATA Challenge 電力価格予想

データ分析コンペの取り組み

コンペの概要

SIGNATE 電力価格の予想(再直近のコンペ)

タスク: スペインの電力価格予想
(時系列データの回帰問題)

評価指標

平均二乗和平方根誤差

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$




データセット

24h前の電力実績とスペインの地方都市の気候のデータをtimeカラムと紐づけて与えられる。

データ分析コンペの取り組み

学習アルゴリズム-プロジェクトの構成-

オレンジ:フォルダ
白色:ファイル




データ分析コンペの取り組み

学習アルゴリズム - アンサンブル学習 -

アンサンブル学習 (スタッキング) とは？

複数のモデルを組み合わせ得た結果を、
さらに別のモデルに学習させ、最終的な結果を得る。



・メリット

異なるモデルを組み合わせることによって、
最終的なモデルの精度が向上する。

文殊の知恵の発想

・デメリット

パイプラインの構築が複雑。
モジュール化し、上手く切り分け、
保守性、拡張性、可読性を担保する
必要がある。

データ分析コンペの取り組み

学習アルゴリズム-アンサンブル学習の具体的な手順-

Level 2 model
LightGBM

モデル

予測1

予測2

予測N

モデル1

モデル2

モデルN

学習データ

Level 1 model

XGBoost、LightGBM、Catboost
N数は使用するモデル数

1. Yamlファイルでハイパラ設定
2. 加工したデータを訓練・検証・テストデータに分割する
3. Level 1で 訓練データから各モデルの予測値を算出
4. 予測値を**新たな特徴量**として、Level2で学習し、最終的な予測値を得る。

データ分析コンペの取り組み

学習アルゴリズム-パッケージ構成-



utility

学習モデルの
ソースファイル

train_exe.py
set_model_params.py
set_fit_params.py
ParamsConfig.py
OptSearchMap.py
make_new_output_dir.py
main.py

local_opt.py
Imports.py
global_opt.py
Fitmodels.py
CustomNeuralNetReg.py
cnvrt_best_params_for_nnet.py
callbacks.py

main.py

Fitmodels.py def main_exe()

アンサンブル学習ver

単一モデル学習ver

def fit_level_one_model()

def fit_level_two_model()

def fit_single_model()

def hypara_search()

def hypara_search()

def hypara_search()

global_opt.py

global_opt.py

global_opt.py

local_opt.py

local_opt.py

local_opt.py

train_exe.py

train_exe.py

train_exe.py

train_exe.py

train_exe.py

train_exe.py

l1_n_trails

epochs

l2_n_trails

s_n_trails

データ分析コンペの取り組み

学習アルゴリズム -特徴のまとめ-

□本学習モデルパッケージの特徴一覧

- ・Yamlファイルでハイパラを一括管理
- ・optunaの自動ハイパラ探索 + K fold交差検証 + 早期終了
global optで複数のstudyをメタ管理、local optでstudyごとの実際のハイパラ探索
lossの平均値をとり、lossが下がる方向にハイパラを自動調整していく。
- ・単一モデルのみの学習にも対応。場合によっては、単一モデルが有効である。
- ・アンサンブル学習できるモデルはすべてscikit-learnライクなモデルで統一。
pytorchはskorchでラッピングして対応させた。fit()、predict()など扱いやすい。
- ・途中経過を観察するため途中で各値や出力を自動で実験フォルダに格納。

データ分析コンペの取り組み

データの可視化 -データセットの概要-

24時間前の各電力実績値

気象データ(スペイン5都市)

電力価格(目的変数)

訓練データ
2015年-
2017年
(train.csv)

Greneration_(biomas,
fossil_gas, nuclear etc...)

timeが識別id

valencia、madrid、bilbao、
barcelona、sevilleの5都市のデータ
例:valencia_temp (valenciaの気温)
その他に、
temp_min, temp_max, pressure,
humidity, wind_speed, wind_deg,
rain_1h, rain_3h, snow_3h, clouds_all,
weather_id, weather_main,
weather_description, weather_icon
がある。

テストデータ
2018年
(test.csv)

予測対象

データ分析コンペの取り組み

データの可視化 -データの欠損値-

訓練データ

```
row_tr_df.isna().sum()¥n  
[row_tr_df.isna().sum() > 0]
```

generation_biomass	21
generation_fossil_brown_coal/lignite	20
generation_fossil_gas	20
generation_fossil_hard_coal	20
generation_fossil_oil	21
generation_hydro_pumped_storage_consumption	21
generation_hydro_run_of_river_and_poundage	21
generation_hydro_water_reservoir	20
generation_nuclear	19
generation_other	20
generation_other_renewable	20
generation_solar	20
generation_waste	21
generation_wind_onshore	20
total_load_actual	37

テストデータ

```
row_test_df.isna().sum()¥n  
[row_test_df.isna().sum() > 0]
```

generation_biomass	2
generation_fossil_brown_coal/lignite	2
generation_fossil_gas	2
generation_fossil_hard_coal	2
generation_fossil_oil	2
generation_hydro_pumped_storage_consumption	2
generation_hydro_run_of_river_and_poundage	2
generation_hydro_water_reservoir	2
generation_nuclear	2
generation_other	2
generation_other_renewable	2
generation_solar	2
generation_waste	2
generation_wind_onshore	2
total_load_actual	3


```
row_tr_df.shape  
=> (26280, 92)  
row_test_df.shape  
=>(8760, 91)
```

訓練データ、テストデータ
ともに欠損値はほぼない。

必要に応じて、
bfill()で欠損値補完する。

データ分析コンペの取り組み

データの可視化 -ヒストグラム- 24時間前の電力実績値



化石ガス、揚水、太陽光の分布は右裾が長い。


原子力の分布は左裾が長い。

化石燃料系の分布は比較的ベル状。

化石燃料系を柱に、その他で補完している。

データ分析コンペの取り組み

データの可視化 -相関係数の絶対値-
24時間前の電力実績値




石炭火力発電、総電力、水力発電、原油火力発電、バイオマス発電が上位を占める。(相関係数0.2以上)

風力、太陽光などは0.1以下と相関は小さい。

高コストな発電ほど電力価格との強い相関が分かる。

データ分析コンペの取り組み

データの可視化 - 散布図 - 24時間前の電力実績値














散布図より、
火力系発電の正の
傾きが可視化。

興味深いのが、
水力発電系だと負
の相関が顕著。

水はコストがかから
ないから？

データ分析コンペの取り組み


データの可視化 -ヒストグラム- Bilbaoの数値カラム



- ・気温、気圧はベル状の分布
- ・湿度は緩やかな左裾の長い分布
- ・風速は右裾の長い分布
- ・降水量、降雪量は一意的に偏った分布

データ分析コンペの取り組み

データの可視化 - 相関係数の絶対値 -
Bilbaoの数値カラム




気圧、風速、雲の割合と
電力価格の相関係数は
0.1以上である。

おそらく、風力や太陽光に
寄与していると考えられる。

データ分析コンペの取り組み


データの可視化 -ヒストグラム- Barcelonaの数値カラム



- ・気温、気圧はベル状の分布
- ・湿度は緩やかな左裾の長い分布
- ・風速は右裾の長い分布
- ・降水量、降雪量は一意的に偏った分布

データ分析コンペの取り組み

データの可視化 - 相関係数の絶対値 -
Barcelonaの数値カラム














風速と電力価格の相関係数は0.1以上である。

おそらく、風力に寄与していると考えられる。
ヒストグラムとも併せて、Barcelonaは気候が安定した土地だと推察できる。

データ分析コンペの取り組み

データの可視化 -ヒストグラム- Madridの数値カラム




気温、湿度は
ベル状の分布。

降水量、降雪量は情
報量がほぼない。

データ分析コンペの取り組み

データの可視化 -相関係数の絶対値- Madridの数値カラム




風速と電力価格の相関係数は0.1以上である。

おそらく、風力に寄与していると考えられる。
ヒストグラムとも併せて、
Madridは気候が安定した土地だと推察できる。

データ分析コンペの取り組み

データの可視化 -ヒストグラム- Valenciaの数値カラム




気温、気圧、湿度は
ベル状の分布。

風速、降水量、降雪
量は情報量がほぼ
ない。

データ分析コンペの取り組み

データの可視化 - 相関係数の絶対値 -
Valenciaの数値カラム














風速と電力価格の相関係数は0.1以上である。

おそらく、風力に寄与していると考えられる。
ヒストグラムとも併せて、Valenciaは気候が安定した土地だと推察できる。

データ分析コンペの取り組み


データの可視化 -ヒストグラム- Sevilleの数値カラム



- ・気温、気圧はベル状の分布
- ・湿度は緩やかな左裾の長い分布
- ・風速は右裾の長い分布
- ・降水量、降雪量は一意的に偏った分布

データ分析コンペの取り組み

データの可視化 - 相関係数の絶対値 -
Sevilleの数値カラム



気圧と電力価格の相関係数は0.1以上である。


おそらく、風力に寄与していると考えられる。

Sevilleは他都市と比べて、気圧、湿度、風速、曇りの割合の相関係数が高めにある。

地理的にスペイン南部の沿岸部で天候がバラツキやすい傾向にありそう。 P-22

データ分析コンペの取り組み

データの可視化 -ヒストグラム- 5都市のカテゴリカラム



・全体的に偏っている。
今回はターゲットエンコード、集約特徴量の生成で扱う。

データ分析コンペの取り組み

データの可視化 -その他の考察-



Madridは唯一の内陸部、
その他は沿岸部であり、
特に風力に適している？

スペイン政府は再生可能
エネルギーに積極的であ
る。総発電の50%以上が
再生可能エネルギーと言
われる。

風速などのカラムとの相
関からも自然エネルギー
の寄与が伺える。

データ分析コンペの取り組み

データの可視化のまとめ

- ・ベル状の分布のカラムが多いが、一意的な値のカラムはいくつか含まれる。
- ・電力のカラムはモデルに強く影響する。
水力、原子力、風力は価格と負の相関、
一方で、火力、バイオマス、総電力は価格と正の相関。
絶対値の比較で、火力、総電力、水力、バイオマスの順に相関が高い。
電力の相関は最大0.4程。
- ・地方都市ごとのカラムはモデルに僅かに影響する。
地方都市の情報はほとんど気候や天気に関するもので、
風速、気圧、曇の割合と電力価格との相関がある程度認められる。
気候の相関は最大0.2程。

データ分析コンペの取り組み

特徴量エンジニアリングの一覧

学習モデル投入前に特徴量エンジニアリングの処理を行う。

- ・分布で一意のラベルに偏ったカラムの除去
- ・タイムスタンプ化： 年、月、日の特徴量生成
- ・年、月をsin/cosにそれぞれ変換
- ・各電力 / 総電力のレシオの特徴量生成
- ・集約特徴量生成： 年、月でグルーピングして平均値をとる。
- ・クラスター化： 都市ごとにグルーピングしてPCA → K-meansクラスタリングを行い、
クラスターIDを特徴量として追加
- ・ターゲットエンコーディング： 年、月でグルーピングして、
目的変数の平均値をカテゴリカラムのラベルの値に変換する。
- ・カテゴリカラムの除去
- ・object型=>category型の明示化

データ分析コンペの取り組み

モデルの学習と結果

□ベースライン

特徴量は前述の通りの設計。

訓練データのサイズ (26280, 92) => (26280, 230)

テストデータのサイズ(8760,91) => (26280, 229)

使用モデル: LightGBM

ハイパラ(一部抜粋)	説明	値
s_n_trails	単体モデルのハイパラ探索トライアル数	10
epochs	ラウンド数、エポック	100
depth	木の最大深さ	8
cv_n	K-foldの分割数	3
max_train_size	時系列k-foldの訓練データの最大数	8500
early_rounds	early stoppingのラウンド数	5
patience_step_threshold	累積studyのカウント数 studyのlossに改善がなければ打ち切り	3

結果

検証スコア 7.21

テストスコア:13.184

データ分析コンペの取り組み

モデルの学習と結果

□修正1

特徴量は前述の通りの設計。

訓練データのサイズ (26280, 92) => (26280, 230)

テストデータのサイズ(8760,91) => (26280, 229)

使用モデル: Lv.1 (LightGBM, XGBoost, Catboost) => L2(LightGBM)

ハイパラ(一部抜粋)	説明	値
l1/l2_n_trails	アンサンブルのハイパラ探索トライアル数	10
epochs	ラウンド数、エポック	100
depth	木の最大深さ	8
cv_n	K-foldの分割数	3
max_train_size	時系列k-foldの訓練データの最大数	8500
early_rounds	early stoppingのラウンド数	5
patience_step_threshold	累積studyのカウント数 studyのlossに改善がなければ打ち切り	3

結果

検証スコア: 6.79

テストスコア: 13.382

検証スコアは低下したが、
テストスコアは増加した。
過学習の疑い。

データ分析コンペの取り組み

モデルの学習と結果

□修正2

l1/l2_n_trails、epochを変更。

訓練データのサイズ (26280, 92) => (26280, 230)

テストデータのサイズ(8760,91) => (26280, 229)

使用モデル: Lv.1 (LightGBM, XGBoost, Catboost) => Lv.2(LightGBM)

ハイパラ(一部抜粋)	説明	値
l1/l2_n_trails	アンサンブルのハイパラ探索トライアル数	20
epochs	ラウンド数、エポック	1000
depth	木の最大深さ	8
cv_n	K-foldの分割数	3
max_train_size	時系列k-foldの訓練データの最大数	8500
early_rounds	early stoppingのラウンド数	5
patience_step_threshold	累積studyのカウント数 studyのlossに改善がなければ打ち切り	3

結果

検証スコア: 6.410

テストスコア: 13.029

トライアル数、エポック数を増やすと、検証・テストスコアともに改善。

データ分析コンペの取り組み

モデルの学習と結果

修正3

特徴量は前述の通りの設計から、**相関係数0.2未満**のカラムを除外

訓練データのサイズ (26280, 230) => (26280, 59)

テストデータのサイズ(8760,229) => (8760, 58)

使用モデル: Lv.1 (LightGBM, XGBoost, Catboost) => Lv.2(LightGBM)

ハイパラ(一部抜粋)	説明	値
l1/l2_n_trails	アンサンブルのハイパラ探索トライアル数	20
epochs	ラウンド数、エポック	1000
depth	木の最大深さ	8
cv_n	K-foldの分割数	3
max_train_size	時系列k-foldの訓練データの最大数	8500
early_rounds	early stoppingのラウンド数	5
patience_step_threshold	累積studyのカウント数 studyのlossに改善がなければ打ち切り	3

結果

検証スコア: 6.534

テストスコア:13.70

検証・テストスコアともに増大。
カラムを大幅に少なくした影響
で、モデルの表現力が低下。

データ分析コンペの取り組み

モデルの学習と結果

□修正3

特徴量は前述の通りの設計から、**相関係数0.1未満**のカラムを除外

訓練データのサイズ (26280, 230) => (26280, 107)

テストデータのサイズ(8760,229) => (8760, 106)

使用モデル: Lv.1 (LightGBM, XGBoost, Catboost) => Lv.2(LightGBM)

ハイパラ(一部抜粋)	説明	値
l1/l2_n_trails	アンサンブルのハイパラ探索トライアル数	20
epochs	ラウンド数、エポック	1000
depth	木の最大深さ	8
cv_n	K-foldの分割数	3
max_train_size	時系列k-foldの訓練データの最大数	8500
early_rounds	early stoppingのラウンド数	5
patience_step_threshold	累積studyのカウント数 studyのlossに改善がなければ打ち切り	3

結果

検証スコア: 6.419

テストスコア:**12.849**

検証・テストスコアともに減少。
相関係数の閾値を緩和し、除外
するカラムを押さえ、モデルの
精度に寄与。

データ分析コンペの取り組み

モデルの学習と結果 -実験のまとめ-

・モデルの精度に寄与する因子

特徴量の生成と選択、学習回数、トライアル数などのハイパラ。
相関係数を基準にすると直観的に選別しやすいので実用的である。

・なぜ、特徴量の調整で精度に影響が出る？

多重共線性の排除で重みの分散を減らした。寄与しない特徴量を除外することで正則化になった。特徴量の数がモデルの表現力を向上させた。

・その他の有効そうな施策

気候データから天気予報を行い、天気予報から需要予測を行い、
未来の総電力を予測し、特徴量に加える。

気温をセルシウス温度に変換、平均値の差分から快適さを考慮。
外部の公的データ(平均所得、世帯数、企業数など)を加える。

ノード数、リーフ数、サブサンプル数などのハイパラ調整。



ご拝読
ありがとうございました。